

จำนวนอนนา

age	income	student	credit_rating	buys_computer
<=30	high	no	fair	no
<=30	high	no	excellent	no
31...40	high	no	fair	yes
>40	medium	no	fair	yes
>40	low	yes	fair	yes
>40	low	yes	excellent	no
31...40	low	yes	excellent	yes
<=30	medium	no	fair	no
<=30	low	yes	fair	yes
>40	medium	yes	fair	yes
<=30	medium	yes	excellent	yes
31...40	medium	no	excellent	yes
31...40	high	yes	fair	yes
>40	medium	no	excellent	no

จากสูตร

- Expected information (entropy) needed to classify a tuple in D:

$$Info(D) = - \sum_{i=1}^m p_i \log_2(p_i)$$

- Information needed (after using A to split D into v partitions) to classify D:

$$Info_A(D) = \sum_{j=1}^v \frac{|D_j|}{|D|} \times Info(D_j)$$

- Information gained by branching on attribute A

$$Gain(A) = Info(D) - Info_A(D)$$

หา $Info(D)$

$$Info(D) = I(9,5) = - \frac{9}{14} \log_2\left(\frac{9}{14}\right) - \frac{5}{14} \log_2\left(\frac{5}{14}\right)$$

$$= 0.94$$

หา $Info_{age}(D)$

$$Info_{age}(D) = \frac{5}{14} I(2,3) + \frac{4}{14} I(4,0) + \frac{4}{14} I(3,2)$$

$$* \text{หา } I(2,3) = - \frac{2}{5} \log_2\left(\frac{2}{5}\right) - \frac{3}{5} \log_2\left(\frac{3}{5}\right) = 0.971$$

$$I(4,0) = - \frac{4}{4} \log_2\left(\frac{4}{4}\right) - \frac{0}{4} \log_2\left(\frac{0}{4}\right) = 0$$

$$I(3,2) = - \frac{3}{5} \log_2\left(\frac{3}{5}\right) - \frac{2}{5} \log_2\left(\frac{2}{5}\right) = 0.971$$

$$\text{หาค่า จะได้ } Info_{age}(D) = \frac{5}{14} (0.971) + \frac{4}{14} (0) + \frac{4}{14} (0.971) = 0.694$$

หา $Gain(age)$

$$Gain(age) = 0.94 - 0.694 = 0.246$$

๑๑ Info_{income} (D)

$$\text{Info}_{\text{income}}(D) = \frac{4}{14} I(2,2) + \frac{6}{14} I(4,2) + \frac{4}{14} I(3,1)$$

$$* \text{๑๑๑๑} \quad I(2,2) = -\frac{2}{4} \log_{(2)}\left(\frac{2}{4}\right) - \frac{2}{4} \log_{(2)}\left(\frac{2}{4}\right) = 1$$

$$I(4,2) = -\frac{4}{6} \log_{(2)}\left(\frac{4}{6}\right) - \frac{2}{6} \log_{(2)}\left(\frac{2}{6}\right) = 0.918$$

$$I(3,1) = -\frac{3}{4} \log_{(2)}\left(\frac{3}{4}\right) - \frac{1}{4} \log_{(2)}\left(\frac{1}{4}\right) = 0.811$$

$$\text{๑๑๑๑๑๑๑๑๑๑} \quad \text{Info}_{\text{income}}(D) = \frac{4}{14}(1) + \frac{6}{14}(0.918) + \frac{4}{14}(0.811) \\ = 0.911$$

๑๑ Gain (income)

$$\text{Gain (income)} = 0.94 - 0.911 = 0.029$$

๑๑ Info_{student} (D)

$$\text{Info}_{\text{student}}(D) = \frac{7}{14} I(6,1) + \frac{7}{14} I(3,4)$$

$$* \text{๑๑๑๑๑๑} \quad I(6,1) = -\frac{6}{7} \log_{(2)}\left(\frac{6}{7}\right) - \frac{1}{7} \log_{(2)}\left(\frac{1}{7}\right) = 0.592$$

$$I(3,4) = -\frac{3}{7} \log_{(2)}\left(\frac{3}{7}\right) - \frac{4}{7} \log_{(2)}\left(\frac{4}{7}\right) = 0.985$$

$$\text{๑๑๑๑๑๑๑๑๑๑๑๑๑๑} \quad \text{Info}_{\text{student}}(D) = \frac{7}{14}(0.592) + \frac{7}{14}(0.985) \\ = 0.789$$

๑๑ Gain (student)

$$\text{Gain (student)} = 0.94 - 0.789$$

$$= 0.151$$

หรือ $\text{Info}_{\text{credit_rating}}(D)$

$$\text{Info}_{\text{credit_rating}}(D) = \frac{8}{14} I(6, 2) + \frac{6}{14} I(3, 3)$$

$$* \text{หา } I(6, 2) = -\frac{6}{8} \log_{(2)}\left(\frac{6}{8}\right) - \frac{2}{8} \log_{(2)}\left(\frac{2}{8}\right) = 0.811$$

$$I(3, 3) = -\frac{3}{6} \log_{(2)}\left(\frac{3}{6}\right) - \frac{3}{6} \log_{(2)}\left(\frac{3}{6}\right) = 1$$

$$\text{หาค่า Info} \text{ จะได้ } \text{Info}_{\text{credit_rating}}(D) = \frac{8}{14} (0.811) + \frac{6}{14} (1) = 0.892$$

หรือ $\text{Gain}(\text{credit_rating})$

$$\text{Gain}(\text{credit_rating}) = 0.94 - 0.892 = 0.048$$

พิจารณาหา Gain ทั้งหมด จะได้


$$\text{Gain}(\text{age}) = 0.246$$

$$\text{Gain}(\text{income}) = 0.029$$

$$\text{Gain}(\text{student}) = 0.151$$

$$\text{Gain}(\text{credit_rating}) = 0.048$$

ให้เลือก Gain ที่มีค่ามากที่สุด มาพิจารณาเงื่อนไขส่วนแรก จะได้ดังนี้



age (≤ 30)

หา Info(D) ของ age (≤ 30) ง่ายๆ ได้

$$\text{Info}(D) = I(2,3) = 0.971$$

หา $\text{Info}_{\text{income}}(D)$ ของ age ง่ายๆ ได้

$$\text{Info}_{\text{income}}(D) \text{ ของ age } (\leq 30) = \frac{2}{5} I(0,2) + \frac{2}{5} I(1,1) + \frac{1}{5} I(1,0)$$

$$* \text{ หา } I(0,2) = -\frac{0}{2} \log_{(2)}\left(\frac{1}{2}\right) - \frac{2}{2} \log_{(2)}\left(\frac{2}{2}\right) = 0$$

$$I(1,1) = -\frac{1}{2} \log_{(2)}\left(\frac{1}{2}\right) - \frac{1}{2} \log_{(2)}\left(\frac{1}{2}\right) = 1$$

$$I(1,0) = -\frac{1}{1} \log_{(2)}\left(\frac{1}{1}\right) - \frac{0}{1} \log_{(2)}\left(\frac{0}{2}\right) = 0$$

$$\text{หาค่า } \text{Info}_{\text{income}}(D) \text{ ของ age } (\leq 30) = \frac{2}{5}(0) + \frac{2}{5}(1) + \frac{1}{5}(0) = 0.4$$

หา Gain(income) ของ age (≤ 30) ง่ายๆ ได้

$$\text{Gain}(\text{income}) \text{ ของ age } (\leq 30) = 0.971 - 0.4 = 0.571$$

หา $\text{Info}_{\text{student}}(D)$ ของ age (≤ 30)

$$\text{Info}_{\text{student}}(D) \text{ ของ age } (\leq 30) = \frac{2}{5} I(2,0) + \frac{3}{5} I(0,3)$$

สังเกต $\text{Yes} \rightarrow \text{Yes}(\text{buy_computer}), \text{No} \rightarrow \text{no}(\text{buy_computer})$

สังเกตแบ่งตัว student เพราะสามารถแบ่งข้อมูลต่างๆ ได้สมบูรณ์

age (>40)

ข1 Info (D) ของ age (>40) จ्ञได้

$$\text{Info (D) ของ age } (>40) = I(3, 2) = 0.991$$

ข1 Info_{income} (D) ของ age (>40)

$$\text{Info}_{\text{income}} (D) \text{ ของ age } (>40) = \frac{3}{5} I(2, 1) + \frac{2}{5} I(1, 1)$$

$$* \text{หา } I(2, 1) = -\frac{2}{3} \log_{(2)} \left(\frac{2}{3} \right) - \frac{1}{3} \log_{(2)} \left(\frac{1}{3} \right) = 0.918$$

$$I(1, 1) = 1$$

แทนค่า จ्ञได้ $\text{Info}_{\text{income}} (D) \text{ ของ age } (>40) = \frac{3}{5} (0.918) + \frac{2}{5} (1) = 0.951$

ข1 Gain (income) ของ age (>40)

$$\text{Gain (income) ของ age } (>40) = 0.991 - 0.951 = 0.02$$

ข1 Info_{student} (D) ของ age (>40)

$$\text{Info}_{\text{student}} (D) \text{ ของ age } (>40) = \frac{3}{5} I(2, 1) + \frac{2}{5} I(1, 1)$$

$$* \text{หา } I(2, 1) = -\frac{2}{3} \log_{(2)} \left(\frac{2}{3} \right) - \frac{1}{3} \log_{(2)} \left(\frac{1}{3} \right) = 0.918$$

$$I(1, 1) = 1$$

แทนค่า จ्ञได้ $\text{Info}_{\text{student}} (D) \text{ ของ age } (>40) = \frac{3}{5} (0.918) + \frac{2}{5} (1) = 0.951$

ข1 Gain (student) ของ age (>40)

$$\text{Gain (student) age } (>40) = 0.991 - 0.951 = 0.02$$

ข1 Info_{credit-rating} (D) ของ age (>40)

$$\text{Info}_{\text{credit-rating}} (D) \text{ ของ age } (>40) = \frac{3}{5} I(3, 0) + \frac{2}{5} I(0, 2)$$

ตัดสิน fair \rightarrow Yes (buy-computer, excellent \rightarrow no (buy-computer)

เลือกแบ่งด้วย credit-rating เนื่องจากสามารถแบ่งข้อมูลต่างๆ ได้อย่างสมบูรณ์

จากคำตอบที่ได้จากการคำนวณทั้งสามตัว สรุปได้ดังนี้

